

# BERT's little minion:

## A tool to normalise time periods extracted from Dutch text



A. Brandsen

Oxford / Online, 10-08-2022



Universiteit  
Leiden  
The Netherlands





# Hello!

I am Alex Brandsen  
Postdoc at the Faculty of Archaeology

 @alex\_brandsen

# BERT's little minion:

## A tool to normalise time periods extracted from Dutch text



A. Brandsen

Oxford / Online, 10-08-2022




Universiteit  
Leiden  
The Netherlands



# Problem: too much text

- Development-led commercial archaeology due to Malta treaty
- More than 80k reports available, growing with ~8k a year
- Search possible on metadata

Archeologische onderzoeksmeldingen in Nederland - 1908-2015



Eenheid: aantal

Bron: RCE - Monumentenregister - ARCHIS



# FULL TEXT SEARCH

Works, but doesn't account for synonymy and polysemy

# Synonymy: Neolithic

- Neolithic
- Late Stone Age
- 3500 BC
- 5000 - 4000 BP
- 4th Millenium BC
- And so on...

# Polysemy: Swifterbant

- Place
- Excavation event
- Pottery type
- Time period

# Named Entity Recognition (NER)

... the excavation in **Amsterdam** was ...  
... fragments of **pottery** nearby ...  
... dated to the **Iron Age**. Other finds ...



# Deep Learning with BERT

(Bidirectional Encoder Representations from Transformers)

- BERT is a SotA deep learning technique (by Google)
- It can 'learn' a language by looking at large amounts of text
- Afterwards, you can teach it to classify, using human-labelled data
- Created ArcheoBERTje, taught it to detect entities
- Accuracy: 74% (Strict micro F1 score over all classes)





# Labelling Full Document Collection

Entity	Total	Unique	Top 5
Artefacts	2,520,492	53,675	pottery, charcoal, flint, bone, brick
Contexts	1,602,124	21,319	pit, ditch, posthole, well, house
Materials	457,031	6,146	wooden, flint, wood, metal, bronze
Locations	3,488,698	147,077	nederland, ' , groningen, noord - brabant, gelderland
Species	928,437	34,540	cow, hazel, sheep, goat, pig
Time Periods	4,698,323	98,445	roman period, iron age, 150 - 210, late medieval, modern
Total	13,695,105	361,202	



## AGNES v2.0 (beta)

Zoek door 60.000 archaeologische rapporten uit het [DANS archief](#).

**Let op:** deze versie is nog niet uitgebreid getest, gebruik op eigen risico. Mocht zich een foutmelding voordoen, of lukt iets niet, mail dan naar [a.brandsen@arch.leidenuniv.nl](mailto:a.brandsen@arch.leidenuniv.nl) en vermeld de foutmelding en de huidige URL (kopieer deze uit de adresbalk).

**Zoekopdracht:**

Gebruik een asterisk (\*) als wildcard, dus "bij\*" vind ook "bijlen" en "bijlfragment". Gebruik "OF" om aan te geven dat niet alle woorden voor hoeven te komen, dus "bijl OF speer" vind ook documenten die maar 1 van de 2 woorden bevatten.

### Tijdsperiode

Optioneel: vul een start en eind jaar in. Gebruik een min streepje (-) voor jaartallen voor Christus.

**Begin jaar:**

**Eind jaar:**

### Specifiek zoeken

Geen goede resultaten? Probeer te zoeken op concepten:

**Artefact:**

**Context:**

**Soortnaam:**

### Niet exact zoeken

Gebruik 'fuzzyness' om niet exact te zoeken, bijvoorbeeld bij spelfouten of meerdere vormen van een woord. Dit kan niet gecombineerd worden met een wildcard (\*) in de zoekopdracht.

Geen fuzzyness (zoekterm moet EXACT voorkomen in tekst)




# The Minion: extracting year ranges

<https://github.com/alexbrandsen/timeperiod2daterange>

- Rules based script: convert entity to start year / end year
- 'Neolithic' → -5200 / -3000 (using thesaurus)
- '1250 BC' → -1250 / -1250
- 'second half 3rd century' → 250 / 300
- '1450 ± 50 BP' → 450 / 550
- 'Third quarter of the 2nd century to the late Medieval period' → 150 / 1450





Discover the world at Leiden University

# Extracting Year Ranges

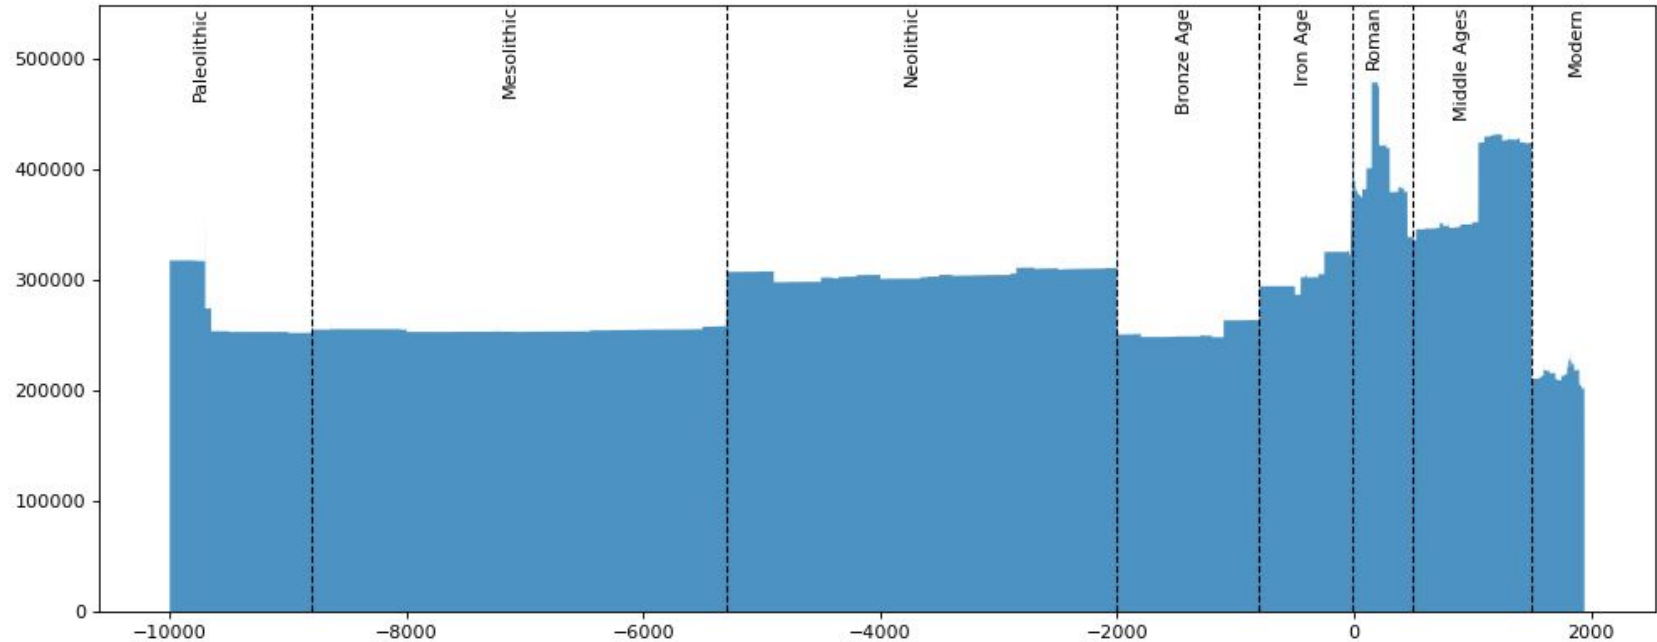



Figure from: Brandsen, A., Verberne, S., Lambers, K., & Wansleebe, M. (2021). Can BERT Dig It? - Named Entity Recognition for Information Retrieval in the Archaeology Domain. *Journal on Computing and Cultural Heritage*. <https://doi.org/10.1145/3497842>

# Future Work

- Multilingual:
  - ▷ German
  - ▷ English
  - ▷ (maybe French?)
- Allows for semantic search:
  - ▷ 'Neolithic' also finds '*Neolithicum*' and '*Kugelamphoren-Kultur*'






# Thanks!

**Any questions?**

a.brandsen@arch.leidenuniv.nl  
alexbrandsen.nl



<https://hdl.handle.net/1887/3274287>